



mongoDB



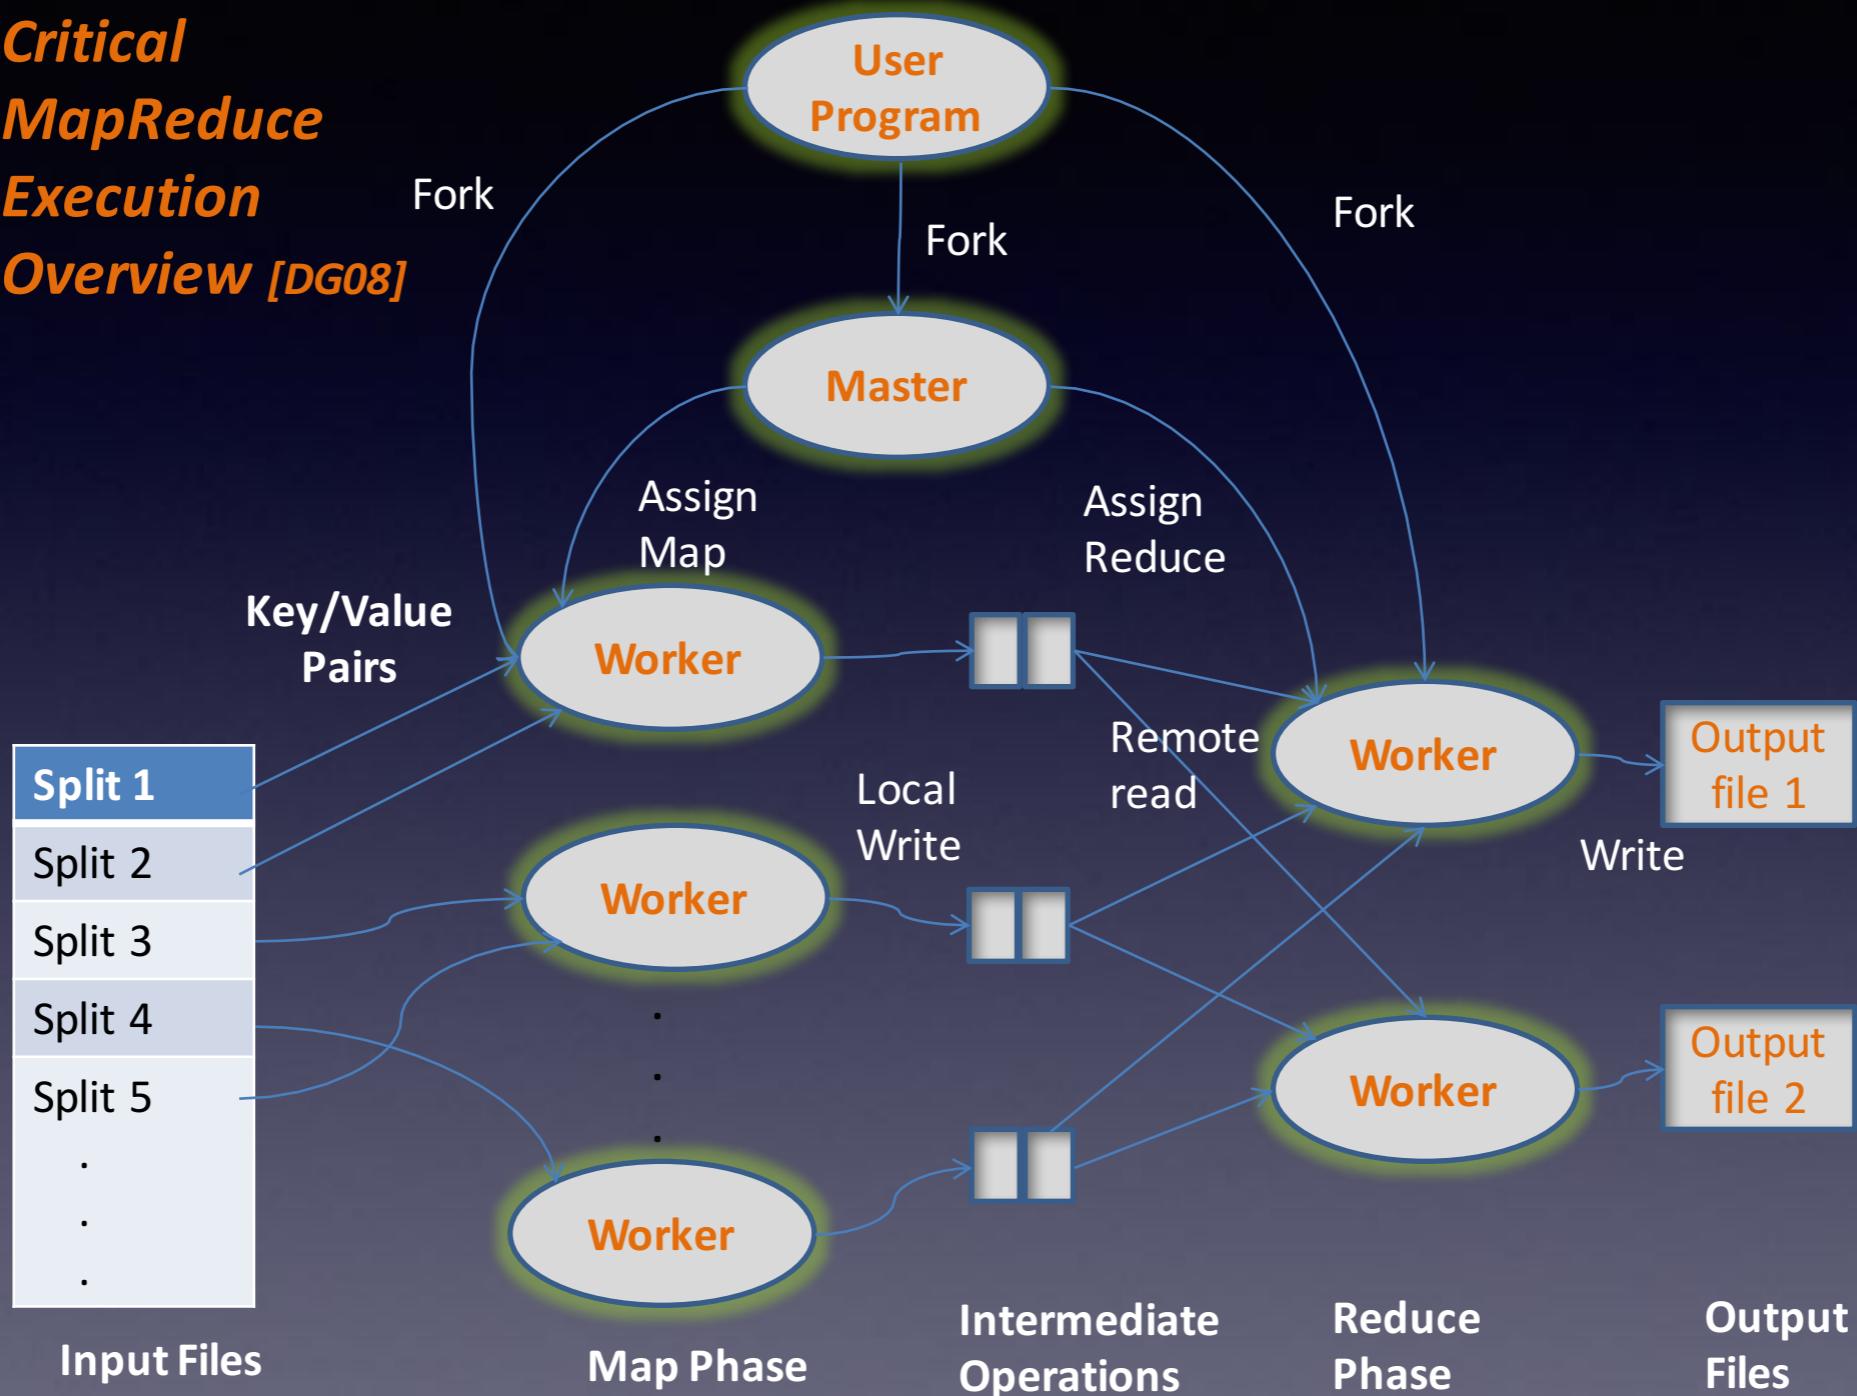
# NoSQL 4-5

MapReduce, Exercises

# Objectifs (aujourd'hui)

- Principes MapReduce
- Exemple
- MapReduce et mongoDB
- Exemple
- TP

**Critical  
MapReduce  
Execution  
Overview [DG08]**



# Le paradigme MapReduce

- MapReduce a été introduit par Google en 2004
- MapReduce est :
  - Un modèle de programmation,
  - avec un schéma très constraint,
  - qui permet :
    - parallélisation automatique,
    - de l'équilibrage de charge,
    - des optimisations sur les transferts disques et réseaux,
    - de la tolérance aux pannes

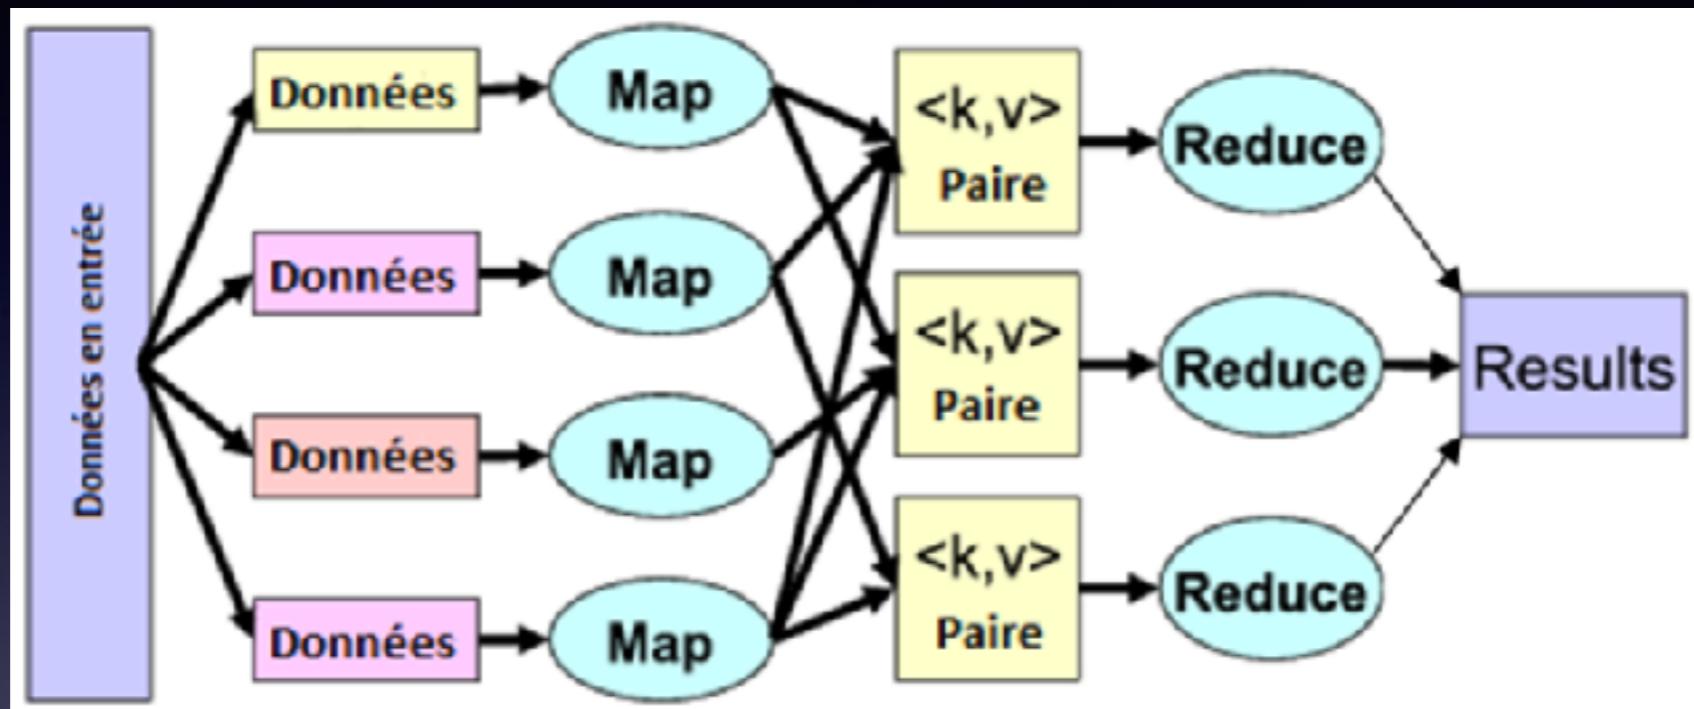
# Qui ?

- Yahoo! Search: Webmap (application Hadoop sur un cluster Linux avec plus de 10.000 coeurs)
- Google: la taille d'une seule phase de computation de l'index a baissé de 3.800 lignes de code (C++) à 700 lignes de code avec MapReduce
- Facebook: plusieurs clusters Hadoop, le plus gros 2.500 coeurs cpu
- Hadoop utilisé par Twitter, Amazon, Rackspace, LinkedIn, IBM, Microsoft, etc.

# MapReduce

- Resolution d'un problème de manière distribuée
  - Découpage en sous-problèmes
  - Execution des sous-problèmes sur les différentes machines du cluster
  - Stratégie algorithmique dite du *Divide et Impera*
- MapReduce
  - Paradigme de programmation parallèle visant à généraliser les approches existantes pour produire une approche unique applicable à tous les problèmes
  - Origine du nom: langages fonctionnels
  - Calcul distribué: "MapReduce: Simplified Data Processing on Large Clusters" [Google, 2004]

# Étapes



- Deux étapes principales :
  - MAP : Emission de paires **<clé, valeur>** pour chaque donnée d'entrée lue
  - Reduce : Regroupement des valeurs de clé identique et application d'un traitement sur ces valeurs de clé commune

# Étapes

- Écrire un programme Map Reduce :
  1. Choisir une manière de découper les données afin que Map soit parallélisable
  2. Choisir la clé à utiliser pour notre problème
  3. Écrire la fonction pour l'opération Map
  4. Écrire la fonction pour l'opération Reduce

# Comptage de mots

- Exemple classique : le comptage de mots
  - Fichiers d'entrée textuels
  - On veut connaître le nombre d'occurrences de chacun des mots dans ces fichiers
- Il faut décider :
  - De la manière dont on découpe les textes
  - Des couples <clé, valeur> à émettre lors du Map appliqué à chaque morceau de texte
  - Du traitement à opérer lors du regroupement des clés communes (Reduce)

# Fichier d'entrée

Celui qui croyait au ciel  
Celui qui n'y croyait pas  
[...]  
Fou qui fait le délicat  
Fou qui songe à ses querelles

(Louis Aragon, *La rose et le Réséda*, 1943,  
fragment)

- Pour simplifier, on retire tout symbole de ponctuation et caractères spéciaux. On passe l'intégralité du texte en minuscules

# Fichier d'entrée

celui qui croyait au ciel

celui qui ny croyait pas

fou qui fait le délicat

fou qui songe a ses querelles

Découpage des données  
d'entrée : par exemple  
par ligne

- Ici, 4 unités de traitement après découpage

## Map

celui qui croyait au ciel

→(celui;1) (qui;1) (croyait;1) (au;1) (ciel;1)

celui qui ny croyait pas

→(celui;1) (qui;1) (ny;1) (croyait;1) (pas;1)

fou qui fait le délicat

→ (fou;1) (qui;1) (fait;1) (le;1) (delicat;1)

fou qui songe a ses querelles

→ (fou;1) (qui;1) (songe;1) (a;1) (ses;1)  
(querelles;1)

- Opération Map :

- Séparation de l'unité en mots (selon les espaces)
- Emission d'une paire <mot,1> pour chaque mot

## Map

(celui;1) (celui; 1)

(fou;1) (fou;1)

(qui;1) (qui;1) (qui;1) (qui;1)

(fait;1)

(le;1)

(delicate;1)

(croyait;1) (croyait;1)

(a;1)

(ses;1)

(au;1) (ny;1) (ciel;1) (pas;1)

(querelles;1)

- Après le Map : regroupement (shuffle) des clés communes
  - Effectué par un tri distribué

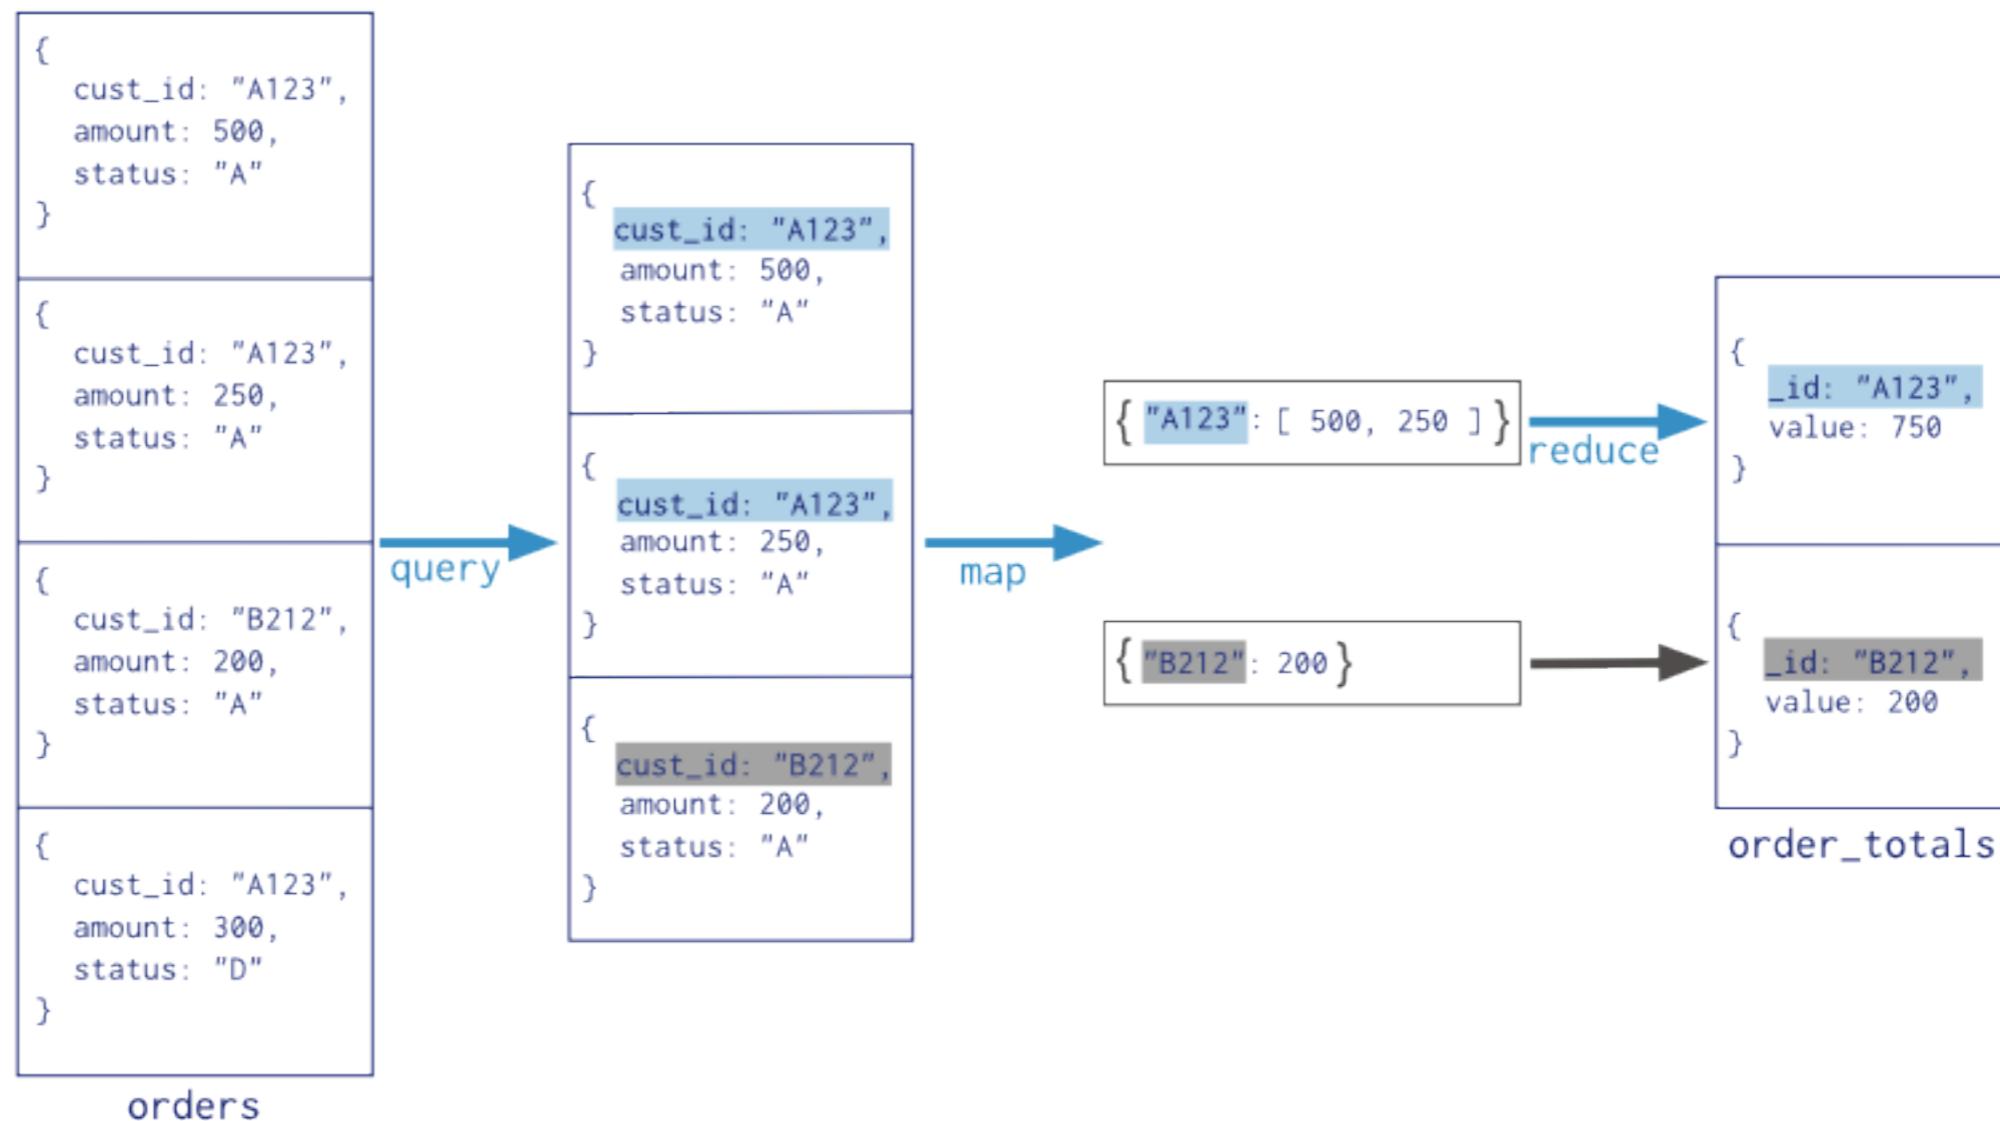
# Reduce

- Opération Reduce :
  - Sommation des valeurs de toutes les paires de clé commune
  - Ecriture dans (ou des) fichier(s) résultats

qui: 4  
celui: 2  
croyait: 2  
fou: 2  
au: 1  
ciel: 1  
ny: 1  
pas: 1  
fait: 1  
[...]

Collection  
`db.orders.mapReduce(`

- `map` → `function() { emit( this.cust_id, this.amount ); },`
- `reduce` → `function(key, values) { return Array.sum( values ) },`
- `query` → `query: { status: "A" },`
- `output` → `out: "order_totals"`

`)`




# Exemple

## Prix total par client

```
{  
  _id: ObjectId("50a8240b927d5d8b5891743c"),  
  cust_id: "abc123",  
  ord_date: new Date("Oct 04, 2012"),  
  status: 'A',  
  price: 25,  
  items: [ { sku: "mmm", qty: 5, price: 2.5 },  
           { sku: "nnn", qty: 5, price: 2.5 } ]  
}
```

```
var mapFunction1 = function() {  
  emit(this.cust_id, this.price);  
};  
  
var reduceFunction1 = function(keyCustId, valuesPrices) {  
  return Array.sum(valuesPrices);  
};
```

**agc**

# Exemple

## Prix total par client

```
db.orders.mapReduce(  
    mapFunction1,  
    reduceFunction1,  
    { out: "map_reduce_example" }  
)
```



# Exemple

Calculer la commande et la quantité totale avec la quantité moyenne par article

```
var mapFunction2 = function() {  
    for (var idx = 0; idx < this.items.length; idx++) {  
        var key = this.items[idx].sku;  
        var value = {count: 1, qty: this.items[idx].qty};  
        emit(key, value);}  
  
var reduceFunction2 = function(keySKU, countObjVals) {  
    reducedVal = { count: 0, qty: 0 };  
    for (var idx = 0; idx < countObjVals.length; idx++) {  
        reducedVal.count += countObjVals[idx].count;  
        reducedVal.qty += countObjVals[idx].qty;  
    }  
    return reducedVal;  
};
```



# Exemple

Calculer la commande et la quantité totale avec la quantité moyenne par article

```
var finalizeFunction2 = function (key, reducedVal) {  
    reducedVal.avg = reducedVal.qty/reducedVal.count;  
    return reducedVal;  
};  
  
db.orders.mapReduce( mapFunction2,  
    reduceFunction2,  
    {  
        out: { merge: "map_reduce_example" },  
        query: { ord_date:  
            { $gt: new Date('01/01/2012') }  
        },  
        finalize: finalizeFunction2  
    }  
)
```

# TP2: MapReduce DBLP

- Téléchargez le sujet depuis: [http://www.lsis.org/  
chifua/#teachings](http://www.lsis.org/chifua/#teachings) (onglet NOSQL - mongoDB → TP)